

RELATÓRIO FINAL - LABORATÓRIO 03

Caracterizando a atividade de code review no GitHub - Sprint 03

Campo	Descrição
Atividade	Análise de Pull Requests revisados em repositórios populares do GitHub
Base auditada	14.347 PRs, 182 repositórios efetivos, snapshot de 30/04/2026
Alunos	Isaac Portela e Miguel Lessa
Data da revisão	07/05/2026

Resumo

Este estudo investiga, por meio de análise quantitativa observacional, quais variáveis de Pull Requests (PRs) se associam ao feedback final da revisão (MERGED ou CLOSED) e ao número de revisões recebidas. A amostra compreende 14.347 PRs distribuídos por 182 repositórios populares do GitHub. Os principais achados indicam que: (i) o tempo de análise é o preditor mais forte do desfecho, com PRs CLOSED apresentando mediana de 519,8 horas contra 40,7 horas dos MERGED (δ de Cliff = $-0,437$, efeito médio); (ii) o tamanho e as interações são os melhores preditores do esforço de revisão ($\rho \approx 0,30-0,34$); e (iii) a descrição exerce influência apenas marginal em ambas as dimensões. Das oito hipóteses formuladas, três foram corroboradas, três refutadas e duas parcialmente corroboradas.

1. Introdução

1.1 Contextualização

A prática de code review constitui elemento central dos processos colaborativos de desenvolvimento de software, especialmente no ecossistema open source hospedado no GitHub. Nesse modelo, toda contribuição é submetida por meio de um Pull Request (PR), o qual passa por inspeção de revisores antes de ser incorporado (MERGED) ou descartado (CLOSED).

Compreender quais fatores influenciam o resultado da revisão e o esforço demandado é relevante tanto para contribuidores, que desejam otimizar suas submissões, quanto para mantenedores, que buscam eficiência nos processos de integração. Este experimento é necessário para fornecer evidências empíricas que permitam separar duas dimensões frequentemente confundidas: aceitação do PR e esforço de revisão.

2. Objetivo e Hipóteses

2.1 Objetivo

Caracterizar empiricamente a atividade de code review nos 200 repositórios mais populares do GitHub, avaliando a relação entre métricas dos PRs, o feedback final e o número de revisões.

2.2 Hipóteses

RQ	Hipótese nula (H0)	Hipótese alternativa (H1)	Resultado
H1	Tamanho não diferencia MERGED/CLOSED	PRs maiores tendem a CLOSED	Refutada
H2	Tempo não diferencia MERGED/CLOSED	Maior tempo associa-se a CLOSED	Corroborada
H3	Descrição não diferencia MERGED/CLOSED	Descrição maior favorece MERGED	Refutada
H4	Interações não diferenciam MERGED/CLOSED	Mais interações tendem a CLOSED	Parcial
H5	Tamanho não se correlaciona com revisões	PRs maiores recebem mais revisões	Corroborada

RQ	Hipótese nula (H0)	Hipótese alternativa (H1)	Resultado
H6	Tempo não se correlaciona com revisões	Maior tempo implica mais revisões	Parcial(fraca)
H7	Descrição não se correlaciona com revisões	Descrição maior reduz revisões	Refutada
H8	Interações não se correlacionam com revisões	Mais interações implicam mais revisões	Corroborada

3. Perguntas de Pesquisa

Dimensão A — *Feedback* final (MERGED vs. CLOSED):

- **RQ 01:** Qual a relação entre o tamanho dos PRs e o *feedback* final?
- **RQ 02:** Qual a relação entre o tempo de análise e o *feedback* final?
- **RQ 03:** Qual a relação entre a descrição do PR e o *feedback* final?
- **RQ 04:** Qual a relação entre as interações no PR e o *feedback* final?

Dimensão B — Número de revisões:

- **RQ 05:** Qual a relação entre o tamanho e o número de revisões?
- **RQ 06:** Qual a relação entre o tempo de análise e o número de revisões?
- **RQ 07:** Qual a relação entre a descrição e o número de revisões?
- **RQ 08:** Qual a relação entre as interações e o número de revisões?

4. Variáveis e Métricas

4.1 Métricas primárias

Categoria	Métrica	Unidade	RQs
Tamanho	changed_files, additions, deletions, loc_total	arquivos / linhas	RQ01, RQ05
Tempo	tempo_analise_horas	horas	RQ02, RQ06
Descrição	descricao_tamanho_chars	caracteres	RQ03, RQ07
Interações	num_participantes, total_comentarios	pessoas / comentários	RQ04, RQ08

4.2 Variáveis dependentes

- **Dimensão A:** status (MERGED / CLOSED) — variável binária.
- **Dimensão B:** numero_reviews — variável numérica de contagem.

4.3 Definições

- LOC total = additions + deletions.
- Tempo de análise = closedAt (ou mergedAt) – createdAt, em horas.
- Participantes = participants.totalCount da API GraphQL (pessoas distintas).

5. Desenho Experimental

- **Tipo:** Estudo quantitativo, observacional e retrospectivo.
- **Unidades de análise:** Pull Requests individuais.
- **Amostra:** 200 repositórios mais populares do GitHub (por estrelas); 182 efetivamente analisados.
- **Critérios de inclusão:** PRs com status $\in \{\text{MERGED}, \text{CLOSED}\}$, pelo menos uma revisão, tempo de análise superior a uma hora.
- **Critérios de exclusão:** Forks, repositórios com menos de 100 PRs fechados.
- **Janela temporal:** Snapshot coletado em 30 de abril de 2026.
- **Tamanho final:** 14.347 PRs (9.728 MERGED, 4.619 CLOSED).

6. Ambiente e Materiais

Material	Finalidade
GitHub REST API v3	Busca inicial dos repositórios mais populares.
GitHub GraphQL API v4	Coleta de PRs, reviews, participantes e metadados.
Python 3.12	Scripts de coleta, enriquecimento, análise e geração de gráficos.
pandas / numpy	Organização, limpeza e sumarização tabular dos dados.
scipy.stats	Mann-Whitney, Spearman, Pearson e testes estatísticos.
matplotlib / seaborn	Visualizações: boxplots, dispersões, violinos e heatmap.

7. Procedimento

- Listar os 200 repositórios mais populares do GitHub por número de estrelas.
- Validar elegibilidade: pelo menos 100 PRs em MERGED + CLOSED.

- Coletar PRs via GraphQL (campos: status, datas, tamanho, descrição, comentários, revisões).
- Aplicar filtros: $\text{status} \in \{\text{MERGED}, \text{CLOSED}\}$, $\text{reviews} \geq 1$, $\text{tempo} > 1$ hora.
- Enriquecer com `participants.totalCount` em segunda passagem GraphQL.
- Persistir dataset em CSV.
- Calcular estatísticas descritivas globais e por status.
- Aplicar testes inferenciais e gerar gráficos.

8. Análise de Dados

8.1 Métodos estatísticos

- **Dimensão A (RQ01–RQ04):** Mann-Whitney U (comparação de dois grupos independentes), δ de Cliff (tamanho de efeito), ponto-bisserial de Pearson (complementar).
- **Dimensão B (RQ05–RQ08):** Spearman ρ (correlação monótona), Pearson em $\log(x+1)$ (verificação em escala expandida).
- **Intervalos de confiança:** 95%, via bootstrap com 1.000 reamostragens.
- **Correção de múltiplas comparações:** Holm step-down ($\alpha = 0,05$) e Bonferroni (referência conservadora).

8.2 Justificativa

As distribuições apresentam forte assimetria com cauda longa (por exemplo, a média do tempo de análise é 2.069 h, contra mediana de 74 h). Essa característica justifica plenamente o uso de testes não paramétricos e da mediana como medida central.

Glossário de termos estatísticos (leitura recomendada)

Para facilitar a compreensão dos resultados, apresenta-se abaixo uma explicação acessível de cada termo estatístico utilizado neste relatório.

Termo	O que é	Analogia simples
Mediana	Valor que divide os dados ao meio: 50% dos PRs ficam acima e 50% ficam abaixo.	Se 10 pessoas estão em uma fila ordenada por altura, a mediana é a altura da pessoa do meio. Diferente da média, ela não é tão afetada por valores extremos.
Média	Soma de todos os valores dividida pela quantidade total de observações.	Se poucos PRs demoram anos, a média sobe muito, mesmo que a maioria demore apenas alguns dias. Por isso, em dados muito desiguais, a mediana costuma representar melhor o comportamento geral.
p-valor	Indica a probabilidade de a diferença observada ter ocorrido por acaso. Quando o p-valor é menor que 0,05, geralmente consideramos o resultado estatisticamente significativo.	Imagine jogar uma moeda 100 vezes e obter 90 caras. O p-valor ajuda a responder: “qual a chance disso acontecer se a moeda for justa?”. Se a chance for muito baixa, suspeitamos que a moeda não é justa.
Mann-Whitney U	Teste estatístico usado para comparar dois grupos, como PRs MERGED e CLOSED, sem exigir que os dados sigam uma distribuição normal.	Em vez de comparar médias, o teste pergunta: “se eu pegar um PR aleatório de cada grupo, qual deles tende a ter valor maior?”.

Delta de Cliff	Mede o tamanho da diferença entre dois grupos na prática, em uma escala de -1 a +1. Ajuda a responder se a diferença é pequena, média ou grande.	Delta = 0 indica grupos muito parecidos. Delta próximo de +1 ou -1 indica grande diferença entre os grupos. Em geral, valores abaixo de 0,15 são desprezíveis; entre 0,15 e 0,33 são pequenos; entre 0,33 e 0,47 são médios; acima de 0,47 são grandes.
Spearman rho	Mede a correlação entre duas variáveis, em uma escala de -1 a +1. Ele indica se, quando uma variável aumenta, a outra também tende a aumentar ou diminuir.	Se $\rho = 0$, não há relação clara. Se $\rho = 0,30$, quando o LOC aumenta, o número de revisões tende a aumentar também, mas com várias exceções. Se $\rho = 1$, a relação seria perfeita.
IC 95%	Intervalo de confiança de 95%. É uma faixa de valores onde provavelmente está o valor real do resultado.	Se a correlação for 0,30 com IC 95% entre 0,28 e 0,32, isso indica que temos boa confiança de que a correlação verdadeira está dentro dessa faixa. Quanto menor o intervalo, mais precisa é a estimativa.
Bootstrap	Técnica que estima a incerteza dos resultados reamostrando os próprios dados várias vezes.	Em vez de coletar novamente milhares de PRs, o computador sorteia várias amostras dos dados existentes e recalcula os resultados. Isso ajuda a estimar intervalos de confiança.
Correção de Holm	Ajuste usado quando fazemos muitos testes estatísticos ao mesmo tempo, para reduzir a chance de falsos positivos.	Se você testar 20 moedas, alguma pode parecer viciada apenas por acaso. A correção de Holm torna o critério mais rigoroso para evitar esse tipo de erro.

ECDF	Função de distribuição acumulada empírica. Mostra, para cada valor, qual porcentagem dos dados está abaixo ou igual a ele.	A curva começa em 0% e vai até 100%. Onde a curva sobe rápido, significa que muitos PRs estão concentrados naquela faixa de valores.
Decil / Quartil	Formas de dividir os dados ordenados. Decis dividem em 10 partes iguais; quartis dividem em 4 partes iguais.	Ao ordenar todos os PRs pelo tempo, o primeiro decil representa os 10% mais rápidos. Já o último decil representa os 10% mais lentos.
Violin plot	Gráfico que mostra a distribuição dos dados, combinando informações de um boxplot com a densidade dos valores.	Onde o violino é mais largo, há mais PRs concentrados. Onde ele é mais fino, há menos PRs. A linha central geralmente indica a mediana.
Hexbin	Gráfico de dispersão que agrupa muitos pontos próximos em hexágonos, facilitando a visualização quando há muitos dados.	Em vez de mostrar milhares de pontos sobrepostos, cada hexágono representa uma região com vários PRs. Quanto mais forte a cor, maior a concentração de PRs naquela região.

9. Resultados

9.1 Estatísticas descritivas globais (n = 14.347)

Antes de responder às RQs, a base precisa ser caracterizada. Essa tabela resume o comportamento típico dos PRs analisados. A leitura principal é que a mediana representa melhor o PR típico do que a média, pois há outliers muito grandes.

Métrica	Mediana	Média	Desvio padrão	p25	p75	p95
Arquivos alterados	2	9,6	101,7	1	5	23
Linhas adicionadas	22	1.137,0	34.259,3	3	121	1.237,1
Linhas removidas	3	199,2	2.809,0	1	21	318

Métrica	Mediana	Média	Desvio padrão	p25	p75	p95
LOC total	33	1.336,2	34.531,9	5	165	1.705,4
Tempo de análise (h)	74,3	2.068,9	6.814,7	13,3	651,7	11.818,0
Descrição (caracteres)	742	1.569,4	3.697,8	170	1.746,0	5.124,4
Participantes	3	3,2	4,7	2	3	6
Comentários	2	3,3	9,8	0	4	11
Revisões	1	3,4	11,6	1	3	10

Observação: A razão média/mediana é extremamente elevada em várias métricas (ex.: 28× para tempo de análise), confirmando a assimetria das distribuições e a necessidade de estatísticas não paramétricas.

9.2 Resultados — Dimensão A (RQ01–RQ04)

Este capítulo responde às RQs 01 a 04. A pergunta central é: quais métricas mudam quando o PR termina aceito ou fechado sem merge? O teste usado foi Mann-Whitney U, acompanhado pelo delta de Cliff para interpretar o tamanho do efeito.


RQ	Métrica	MERGED	CLOSED	p-Holm / Cliff δ	Efeito
RQ01	Arquivos alterados	2	2	< 0,001 / 0,1063	desprezível ₁
RQ01	Linhas adicionadas	22	23	0,788 / 0,0028	desprezível ₁
RQ01	Linhas removidas	4	2	< 0,001 / 0,1711	pequeno
RQ01	LOC total (add+del)	34	31	0,007 / 0,0301	desprezível ₁
RQ02	Tempo de análise (h)	40,7	519,8	< 0,001 / -0,4367	medio
RQ03	Tamanho da descrição (chars)	698	843	< 0,001 / -0,0431	desprezível ₁
RQ04	Numero de participantes	3	3	< 0,001 / -0,0827	desprezível ₁
RQ04	Total de comentarios	1	2	< 0,001 / -0,1547	pequeno

Convenção: δ positivo indica MERGED > CLOSED na métrica; negativo, MERGED < CLOSED.

A Tabela apresenta os resultados da Dimensão A, referente às RQs 01 a 04, comparando PRs aceitos com merge e PRs fechados sem merge. Os resultados mostram que, embora várias métricas apresentem significância estatística após a correção de Holm, a maioria possui tamanho de efeito desprezível ou pequeno segundo o delta de Cliff. A principal exceção é o tempo de análise, que apresenta efeito médio, com mediana de 40,7 horas para PRs MERGED e 519,8 horas para PRs CLOSED. Isso indica que PRs fechados sem merge tendem a

permanecer muito mais tempo em análise. As métricas de tamanho, descrição e participação apresentam diferenças estatisticamente detectáveis, mas com baixa relevância prática.

Figura 1 — Tamanho do efeito (δ de Cliff) para todas as métricas da Dimensão A.



Interpretação da Figura 1: Cada barra horizontal representa uma métrica. O comprimento da barra mostra o quanto essa métrica diferencia os PRs aceitos (MERGED) de rejeitados (CLOSED). Barras verdes apontam para a direita quando o valor é maior em MERGED; barras vermelhas apontam para a esquerda quando é maior em CLOSED. A leitura principal é simples: apenas o tempo de análise apresenta uma barra grande ($\delta = -0,437$, efeito médio), significando que se pegarmos um PR aceito e um rejeitado aleatoriamente, em cerca de 72% das vezes o rejeitado terá ficado aberto por mais tempo. Todas as outras métricas têm barras curtas (efeito desprezível), ou seja, saber o tamanho, a descrição ou o número de participantes de um PR praticamente não ajuda a adivinhar se ele será aceito ou rejeitado. As linhas pontilhadas verticais marcam os limites do efeito desprezível ($|\delta| < 0,147$): barras que ficam dentro dessa faixa são consideradas insignificantes na prática.




Figura 2 — Distribuição do tempo de análise por status (violino comparativo)

Interpretação da Figura 2: Cada "violino" mostra como os tempos de análise se distribuem dentro de cada grupo. Onde o violino é mais largo, há mais PRs com aquele tempo; onde é mais fino, há poucos. A linha tracejada no meio de cada violino marca a mediana (o valor do meio). Observa-se que: (1) o violino verde (MERGED) é mais gordo em baixo, indicando que a maioria dos PRs aceitos é resolvida rapidamente — metade em menos de 41 horas (~1,7 dias); (2) o violino vermelho (CLOSED) é mais gordo em cima e mais largo no geral, mostrando que PRs rejeitados ficam abertos por muito mais tempo — metade leva mais de 520 horas (~21,7 dias). Em termos práticos: PRs aceitos são resolvidos aproximadamente 13 vezes mais rápido do que os rejeitados. Curiosamente, o violino de CLOSED tem dois "bicos" (bimodal), sugerindo dois perfis: PRs que são rejeitados rápido e PRs que ficam "esquecidos" antes de serem fechados.




Figura 4 — Taxa de MERGED por decil de tempo de análise

Interpretação da Figura 4: Aqui dividimos todos os PRs em 10 grupos iguais, do mais rápido (decil 1) ao mais lento (decil 10), e mostramos qual porcentagem de cada grupo foi aceita. A linha tracejada horizontal mostra a média geral (~68%). A leitura é clara: nos primeiros 6 grupos (PRs mais rápidos), cerca de 80% são aceitos — bem acima da média. A partir do 7º grupo, a taxa cai drasticamente, e no grupo dos 10% mais lentos, apenas ~25% são aceitos. Isso significa que o tempo não tem um efeito gradual, mas sim um efeito de limiar: existe uma faixa de tempo após a qual as chances de aceitação despencam. Para um desenvolvedor, a mensagem é direta: quanto mais rápido o PR for analisado, maior a probabilidade de ser aceito.

9.3 Resultados — Dimensão B (RQ05–RQ08)

RQ	Métrica	ρ Spearman	IC 95%	p-Holm	Interpretação
RQ05 ▾	Arquivos alterados	0,270	[0,254; 0,285]	< 0,001 ▾	Fraca positiva ▾
RQ05 ▾	Linhas adicionadas	0,315	[0,300; 0,329]	< 0,001 ▾	Moderada po... ▾

RQ05 ▾	Linhas removidas	0,183	[0,168; 0,200]	< 0,001 ▾	Fraca positiva ▾
RQ05 ▾	LOC total	0,302	[0,287; 0,316]	< 0,001 ▾	Moderada po... ▾
RQ06 ▾	Tempo de análise (h)	0,110	[0,094; 0,126]	< 0,001 ▾	Fraca positiva ▾
RQ07 ▾	Descrição (chars)	0,185	[0,169; 0,202]	< 0,001 ▾	Fraca positiva ▾
RQ08 ▾	Participantes	0,342	[0,327; 0,356]	< 0,001 ▾	Moderada po... ▾
RQ08 ▾	Comentários	0,330	[0,315; 0,344]	< 0,001 ▾	Moderada po... ▾




Figura 5 — Spearman ρ com IC 95% para todas as métricas da Dimensão B.

Interpretação da Figura 5: Este gráfico responde à pergunta: "quais características do PR fazem com que ele receba mais revisões?" Cada barra mostra o Spearman ρ — uma medida de o quanto a métrica "anda junto" com o número de revisões (quanto mais longa a barra, mais forte a relação). Os traços pretos no final de cada barra mostram o intervalo de confiança (a faixa onde o valor verdadeiro provavelmente está). As quatro métricas mais fortes são: participantes ($\rho = 0,342$), comentários (0,330), linhas adicionadas (0,315) e LOC total (0,302). Em linguagem simples: PRs com mais pessoas envolvidas, mais discussão e

mais código alterado tendem a passar por mais ciclos de revisão. Um achado importante: o tempo de análise, que era o melhor preditor de aceitação/rejeição (Figura 1), é o pior preditor do número de revisões ($\rho = 0,110$). Isso confirma que aceitação e esforço de revisão são coisas diferentes.




Figura 6 — Dispersão LOC total $\times$ revisões (hexbin, escala log).

Interpretação da Figura 6: Cada hexágono colorido representa uma "região" do gráfico onde se concentram PRs. Cores mais escuras (vermelho/laranja) = muitos PRs ali; cores claras (amarelo) = poucos PRs. Os eixos usam escala logarítmica para acomodar valores que vão de 1 a centenas de milhares. A concentração de hexágonos escuros no canto inferior esquerdo mostra que a grande maioria dos PRs é pequena (poucas linhas de código) e recebe poucas revisões (1 a 3). Conforme avançamos para a direita (PRs maiores), os hexágonos sobem um pouco, indicando que PRs maiores tendem a receber mais revisões, mas com muita variação.

Um PR de 1.000 linhas pode receber 1 revisão ou 50. Essa é a natureza de uma correlação moderada ($\rho = 0,302$): a tendência existe, mas não é uma regra rígida.




Figura 7 — Dispersão comentários × revisões (hexbin, escala log).

Interpretação da Figura 7: Comparando com a Figura 6, nota-se que aqui a "nuvem" de hexágonos sobe de forma mais acentuada, a diagonal é mais clara. Isso significa que a relação entre comentários e revisões é mais forte do que a relação entre tamanho e revisões ($\rho = 0,330$ vs. $0,302$). Esse resultado faz sentido intuitivo: comentários e revisões são formas de interação entre as pessoas. Quando um PR gera muito debate (muitos comentários), é natural que ele também passe por mais ciclos de revisão, pois os revisores pedem mudanças, o autor responde, e o processo se repete. A grande concentração de hexágonos escuros na base (0–1 comentário, 1 revisão) revela que a maioria dos PRs é simples e aceita sem discussão — o que é esperado em projetos maduros.




Figura 8 — Distribuição de revisões por quartil de LOC total.

Interpretação da Figura 8: Aqui, os PRs foram divididos em 4 grupos de tamanho igual: Q1 (25% menores), Q2, Q3 e Q4 (25% maiores). Para cada grupo, o gráfico mostra como se distribui o número de revisões. A leitura é direta: conforme os PRs ficam maiores (da esquerda para a direita), a "caixa" sobe, indicando que PRs maiores recebem mais revisões. Além disso, nos grupos Q3 e Q4, a cauda superior (PRs com muitas revisões) é muito mais longa, o que significa que PRs grandes não apenas recebem mais revisões em média, como também são mais imprevisíveis, alguns são revisados rapidamente, outros passam por dezenas de ciclos. Para um desenvolvedor, a lição prática é: PRs pequenos reduzem tanto o número de revisões quanto a incerteza do processo.

10. Discussão e Interpretação

10.1 Confronto questão a questão

RQ01 — Tamanho × feedback final: As medianas de LOC total são essencialmente idênticas entre os grupos (34 em MERGED vs. 31 em CLOSED), com δ de Cliff desprezível (+0,03). Hipótese refutada. O tamanho do PR, isoladamente, não prediz o desfecho.

RQ02 — Tempo de análise × feedback final: A mediana do tempo em MERGED (40,7 h) é aproximadamente 13 vezes menor que em CLOSED (519,8 h). O δ de Cliff (-0,437) configura o efeito mais forte observado. Hipótese corroborada.

RQ03 — Descrição × feedback final: A mediana da descrição é maior em CLOSED (843 chars) do que em MERGED (698 chars), com efeito desprezível. Hipótese refutada. Descrições longas tendem a acompanhar PRs controversos.

RQ04 — Interações × feedback final: Comentários apresentam mediana maior em CLOSED (2 vs. 1), com efeito pequeno ($\delta = -0,155$). Participantes não diferenciaram os grupos. Hipótese parcialmente corroborada.

RQ05 — Tamanho × revisões: LOC total apresenta $\rho = 0,302$ (moderada positiva). Hipótese corroborada. O tamanho não prediz o desfecho (RQ01), mas prediz o esforço de revisão.

RQ06 — Tempo × revisões: $\rho = 0,110$ (fraca positiva). Hipótese corroborada com efeito fraco. Um PR pode permanecer aberto sem novas revisões.

RQ07 — Descrição × revisões: $\rho = 0,185$ (fraca positiva, contrária à expectativa). Hipótese refutada. Descrições longas acompanham PRs complexos que demandam mais revisões.

RQ08 — Interações × revisões: $\rho = 0,342$ (participantes) e $0,330$ (comentários), ambos moderada positiva. Hipótese corroborada.

10.2 Comparação cruzada (Dimensão A vs. Dimensão B)

Categoria	δ Cliff (Dim. A)	ρ Spearman (Dim. B)	Interpretação
Tamanho	+0,030 (desprezível)	+0,302 (moderada)	Não prediz desfecho; prediz esforço
Tempo	-0,437 (médio)	+0,110 (fraca)	Prediz desfecho mais que esforço
Descrição	-0,043 (desprezível)	+0,185 (fraca)	Pouca influência em ambas
Interações	-0,155 (pequeno)	+0,330 (moderada)	Mais comentários → CLOSED e mais revisões




Figura 9 — Cruzamento das duas dimensões: efeito no desfecho (δ) vs. efeito no esforço (ρ).

Interpretação da Figura 9: Este gráfico é o mais importante do relatório, pois cruza as duas perguntas centrais do estudo em uma única imagem. O eixo horizontal (X) mostra o quanto cada métrica influencia a aceitação/rejeição do PR (δ de Cliff — quanto mais à esquerda, mais associada a CLOSED). O eixo vertical (Y) mostra o quanto cada métrica influencia o número de revisões (ρ de Spearman — quanto mais acima, mais revisões). A leitura por posição é: Canto inferior esquerdo (tempo de análise): é o campeão em prever aceitação, mas quase não prevê esforço. Parte superior central (participantes, comentários): são os campeões em prever esforço, com impacto modesto na aceitação. Parte superior direita (LOC, adições, arquivos): preveem esforço de revisão, mas não a aceitação. Centro (descrição): influência fraca em tudo. A conclusão visual é que nenhuma métrica é "boa em tudo" ao mesmo tempo — aceitar e revisar são processos governados por fatores diferentes.

10.3 Limitações (ameaças à validade)

- Snapshot temporal único (30/04/2026): tendências do ecossistema podem mudar.
- Viés de popularidade: a amostragem dos 200 repositórios mais estrelados exclui projetos menores.
- Heurística de 1 hora: pode falhar em bots lentos ou PRs legítimos rápidos.
- Subamostragem: até 100 PRs validados por repositório para projetos de altíssimo volume.
- Confundimento: testes univariados não isolam efeitos confundidos; análise multivariada é trabalho futuro.

10.4 Comparação com a literatura

- Gousios, Pinzger e van Deursen (2014): corroboram parcialmente a importância do tempo; contestamos a centralidade da descrição.
- Tsay, Dabbish e Herbsleb (2014): corroboramos a importância dos fatores sociais (interações/comentários).
- Yu et al. (2015): corroboramos o efeito do tamanho sobre o esforço; contestamos a centralidade da descrição.
- Kononenko, Baysal e Godfrey (2016): complementamos o modelo misto (técnico + social) em escala agregada.

11. Conclusão e Recomendações

11.1 Decisões práticas

- Para maximizar aceitação: priorizar PRs que possam ser fechados rapidamente. A mediana de MERGED é 40,7 h contra 519,8 h dos CLOSED.
- Para reduzir esforço de revisão: manter PRs menores em LOC e reduzir ciclos de discussão.
- Quanto à descrição: boa prática, mas o ganho objetivo nas métricas agregadas é discreto.

11.2 Sugestões para trabalhos futuros

- Regressão logística para status para analisar múltiplas variáveis ao mesmo tempo e Binomial Negativa para numero_reviews, ajudando a saber quais fatores aumentam a quantidade esperada de revisões em um PR.
- Segmentação por linguagem, domínio e maturidade do repositório.
- Inclusão de métricas de CI/CD (checks, presença de bots).
- Estudo longitudinal por repositório ao longo do tempo.

11.3 Resultado conclusivo

Em uma amostra de 14.347 PRs distribuídos por 182 repositórios populares, o tempo de análise mostrou-se o preditor mais forte do desfecho ($\delta = -0,44$, efeito médio). Os melhores preditores do esforço de revisão são as interações ($p \approx 0,33$) e o tamanho ($p \approx 0,30$). O tamanho não prediz o desfecho, e a descrição apresenta influência apenas marginal em ambas as dimensões.

12. Reprodutibilidade

1. Coleta (≈ 90 min)

python scripts/coleta_graphql_PRs.py

2. Enriquecimento (≈ 25 min)

python scripts/enriquecer_participantes.py

3. Análise estatística

python scripts/analise_sprint3.py

4. Gráficos aprimorados

python scripts/graficos_aprimorados.py

- Dados: output/lab3s2/pull_requests_com_reviews.csv
- Resultados: output/lab3s3/
- Gráficos: output/lab3s3/charts_v2/

Referências

GOUSIOS, G.; PINZGER, M.; VAN DEURSEN, A. An Exploratory Study of the Pull-based Software Development Model. In: ICSE, 2014. DOI: 10.1145/2568225.2568260.

TSAY, J.; DABBISH, L.; HERBSLEB, J. Influence of Social and Technical Factors for Evaluating Contribution in GitHub. In: ICSE, 2014. DOI: 10.1145/2568225.2568315.

YU, Y.; WANG, H.; FILKOV, V.; DEVANBU, P.; VASILESCU, B. Wait for It: Determinants of Pull Request Evaluation Latency on GitHub. In: MSR, 2015. DOI: 10.1109/MSR.2015.42.

KONONENKO, O.; BAYSAL, O.; GODFREY, M. W. Code Review Quality: How Developers See It. In: ICSE, 2016. DOI: 10.1145/2884781.2884840.