

RELATÓRIO FINAL - LABORATÓRIO 04 (SPRINT 03)

Visualização de Dados Abertos Governamentais: Despesas da CEAP na Câmara dos Deputados

Disciplina: Laboratório de Experimentação de Software **Curso:** Engenharia de Software

Professor: Danilo de Quadros Maia Filho

Autores: (Isaac Portela é Miguel Lessa)

Data: 28 de maio de 2026

Repositório: github.com/Miguel-Lessa/lab-medicao

(<https://github.com/Miguel-Lessa/lab-medicao>) - pasta laboratorio4/

SUMARIO

1. Introdução	2
1.1 Contextualização	2
1.2 Problema foco do experimento	3
1.3 Questões de pesquisa	3
1.4 Hipóteses	3
1.5 Objetivos	4
2. Metodologia	4
2.1 Passo a passo do experimento	4
2.2 Decisões metodológicas	5
2.3 Materiais utilizados	5
2.4 Métodos utilizados	5
2.5 Métricas e unidades	6
3. Caracterização do dataset	6
3.1 Visão geral (período completo 2020-2025)	6
3.2 Caracterização por ano (subgrupo temporal)	7
3.3 Figura de caracterização (única no relatório)	7
4. Visualização dos resultados (5 figuras)	8
Figura 1 - Valor líquido total por ano (caracterização)	8
4.1 RQ1 - Tipos de despesa (Figura 2)	8
Figura 2 - Pareto dos tipos de despesa	9
4.2 RQ2 - Partido e UF (Figura 3 + tabelas)	9
Figura 3 - Mediana do gasto por deputado, por partido	10

4.3 RQ3 - Deputados e fornecedores (Figuras 4 e 5)	10
Figura 4 - Top deputados por valor liquidado	11
Figura 5 - Top fornecedores por valor liquidado	12
5. Discussão dos resultados	12
5.1 Confronto com as questões de pesquisa	12
5.2 Insights	13
5.3 Comparações e estatísticas	13
5.4 Confronto com trabalhos e literatura (Plus)	13
6. Conclusão	14
6.1 Tomada de decisão	14
6.2 Sugestões futuras	14
6.3 Resultado conclusivo	15
Referências	15
Apêndice A - Como reproduzir figuras e dashboard	15
Apêndice B - Entregáveis do Lab04 (checklist)	15
Índice das 5 figuras deste relatório	16

1. Introdução

1.1 Contextualização

Business Intelligence (BI) transforma grandes volumes de dados operacionais em informação para decisão. No setor público brasileiro, portais de **dados abertos** - como o da Câmara dos Deputados (<https://dadosabertos.camara.leg.br/>) - permitem auditoria social e pesquisa sobre uso de recursos parlamentares. A CEAP cobre despesas de exercício da atividade parlamentar (deslocamentos, divulgação, manutenção de escritório, entre outras), sendo uma das bases mais utilizadas em jornalismo de dados e estudos de transparência.

O Laboratório 04 da disciplina solicita a construção de um **dashboard autoexplicativo** com (i) **caracterização do dataset** e (ii) **visualizações que respondam a questões de pesquisa**, com métricas e rótulos adequados. Como trabalho alternativo (sem vínculo com TIS 6), adotou-se base governamental pública e relatório com introdução, metodologia, resultados e discussão.

1.2 Problema foco do experimento

Como visualizar e explorar de forma clara, reproduzível e comparável os padrões de gastos da CEAP entre 2020 e 2025, permitindo identificar concentrações por categoria,

diferenças entre grupos políticos e geográficos, e os maiores valores por parlamentar e fornecedor?

O problema não é detectar fraude automaticamente, e sim **organizar e comunicar** os dados para que cidadãos, pesquisadores e gestores compreendam *onde, quando e em que categorias* os recursos se concentram.

1.3 Questões de pesquisa

ID	Questão de pesquisa
RQ1	Quais tipos de despesa concentram mais gastos parlamentares?
RQ2	Como os gastos variam por partido e por UF?
RQ3	Quais deputados e fornecedores concentram os maiores valores?

1.4 Hipóteses

As hipóteses abaixo orientam a análise exploratória (não foram testadas inferencialmente neste laboratório):

ID	Hipótese
H1	Poucas categorias de despesa concentram a maior parte do valor líquido total (padrão de Pareto).
H2	Partidos com maiores bancadas aparecem no topo do ranking por soma total , mas não necessariamente por mediana de gasto por deputado .
H3	UFs mais populosas lideram em volume absoluto , porém UFs menores podem apresentar mediana por deputado semelhante ou superior.
H4	Fornecedores do setor aéreo e de mídia/divulgação dominam os maiores valores agregados no período.
H5	O valor por lançamento é fortemente assimétrico (muitos lançamentos de baixo valor e cauda longa de valores altos).

1.5 Objetivos

Objetivo geral: Produzir um dashboard e relatório de BI sobre a CEAP (2020-2025) que caracterize o dataset e respondam às RQ1-RQ3 com visualizações adequadas e exportáveis.

Objetivos específicos:

1. Coletar e tratar automaticamente os CSV anuais publicados pela Câmara.
2. Caracterizar volume, cobertura temporal, cardinalidade e distribuição dos valores.
3. Implementar visualizações por tipo de despesa, partido, UF, deputado e fornecedor.
4. Comparar métricas de **soma** e **mediana por deputado** para evitar viés de tamanho de grupo.
5. Disponibilizar exportação de gráficos (PNG/HTML) para inclusão em relatório e PDF.

2. Metodologia

2.1 Passo a passo do experimento

1. Definição do recorte (CEAP, anos 2020-2025) e das RQ1-RQ3
2. Coleta automatizada dos ZIPs anuais (script coleta_ceap.py)
3. Extração e consolidação dos CSVs brutos
4. Tratamento e padronização (script prepara_dados.py)
5. Geração da base analítica: output/despesas_ceap_tratadas.csv
6. Desenvolvimento do dashboard Streamlit (app/dashboard.py)
7. Exploração interativa com filtros (ano, mês, partido, UF, tipo, deputado)
8. Exportação das figuras para o relatório (scripts/exportar_figuras_relatorio.py)
9. Redação do relatório com interpretação alinhada ao enunciado do Lab04

2.2 Decisões metodológicas

Decisão	Justificativa
Ferramenta: Python (Streamlit + Plotly) em vez de Power BI/Tableau	Reprodutibilidade, versionamento no Git e integração com scripts de coleta/tratamento. Atende ao trabalho alternativo do enunciado.
Métrica principal: valor_liquido	Valor efetivamente considerado após glosa; padrão em análises da CEAP.
Tempo: ano/mês de competência (data_referencia)	A data de emissão do documento pode não coincidir com o período de ressarcimento.
Duas agregações em RQ2: soma total e mediana por deputado	Soma reflete tamanho do grupo; mediana aproxima comparação “por parlamentar”.
Heatmap em % por partido	Mostra <i>composição</i> do gasto, não apenas volume bruto.

Decisão	Justificativa
Pizza com fatia “Outros”	Evita gráfico parcial que não soma 100%.
Exclusão opcional de lideranças (LID/LIDER)	Estruturas partidárias não são deputados individuais; filtro no dashboard.

2.3 Materiais utilizados

Material	Descrição
Dados brutos	Ano-2020.csv ... Ano-2025.csv em <code>laboratorio4/data/raw/</code>
Dados tratados	<code>laboratorio4/output/despesas_ceap_tratadas.csv</code>
Scripts	<code>coleta_ceap.py</code> , <code>prepara_dados.py</code> , <code>exportar_figuras_relatorio.py</code>
Dashboard	<code>laboratorio4/app/dashboard.py</code>
Figuras do relatório	<code>laboratorio4/relatorios/figuras/*.png</code>
Dependências	<code>pandas</code> , <code>plotly</code> , <code>streamlit</code> , <code>requests</code> , <code>kaleido</code>

Fonte oficial: Portal de Dados Abertos - Câmara dos Deputados
 (<https://dadosabertos.camara.leg.br/>) · Arquivos CEAP:
<http://www.camara.leg.br/cotas/Ano-{ano}.csv.zip>

2.4 Métodos utilizados

- **Coleta:** download HTTP dos ZIPs anuais e extração local.
- **ETL:** renomeação de colunas, parsing de valores monetários (formato BR), datas, campos derivados (`ano_mes`, `data_referencia`, `flag eh_lideranca`).
- **Agregação:** `groupby` com soma, contagem, mediana e percentuais.
- **Visualização:** barras horizontais, linhas temporais, histograma, diagrama de Pareto, pizza, boxplot, heatmap (Plotly).
- **Interação:** filtros multiselect no Streamlit; exportação PNG/HTML por gráfico.

2.5 Métricas e unidades

Métrica	Definição	Unidade	Uso principal
Valor líquido	vlrLiquido após tratamento	R\$ (BRL)	Todas as RQs
Registros	Contagem de lançamentos	inteiro	Caracterização
Deputados distintos	nunique(deputado)	inteiro	Caracterização; base da mediana em RQ2
Mediana por lançamento	Mediana de valor_liquido onde valor > 0	R\$	Caracterização (H5)
Mediana por deputado (grupo)	Mediana da soma por deputado dentro de partido/UF	R\$	RQ2 (comparação justa)
Percentual / Pareto	Participação e % acumulado por tipo	%	RQ1 (H1)
Composição partido × tipo	% da soma do partido em cada tipo	%	RQ2 (heatmap)

3. Caracterização do dataset

3.1 Visão geral (período completo 2020-2025)

Indicador	Valor
Lançamentos	1.271.817
Valor líquido total	R\$ 1.389.844.978,70
Nomes distintos (deputado/estrutura)	927
Partidos	27
UFs / categorias territoriais	28
Fornecedores distintos	67.783
Mediana por lançamento (valor > 0)	R\$ 259,10
Média por lançamento (valor > 0)	R\$ 1.130,98
Percentil 95 por lançamento	R\$ 5.000,00
Lançamentos com valor zero	42.927

A competência observada estende-se de **janeiro/2020 a dezembro/2025**. O número de **927** nomes acumula mandatos, trocas de identificação e estruturas como LID.GOV-CD e lideranças partidárias; por ano, há entre **554 e 800** nomes distintos.

3.2 Caracterização por ano (subgrupo temporal)

Ano	Registros	Valor líquido (R\$)	Deputados distintos
2020	166.786	175.930.552,00	554
2021	218.439	214.353.823,00	582
2022	209.227	222.512.800,00	572
2023	236.772	262.336.900,00	800
2024	232.259	264.320.800,00	594
2025	208.334	250.390.000,00	574


Há crescimento do **valor total anual** ao longo do período (com exceção de 2025 ligeiramente abaixo de 2024 em valor, mantendo volume elevado de lançamentos). O pico de **800** deputados distintos em 2023 pode refletir mudanças de cadastro ou maior granularidade de registros naquele ano.

3.3 Figura de caracterização (única no relatório)

Os demais indicadores da Seção 3.1-3.2 permanecem em **tabelas** para leitura rápida. Evolução mensal, histograma e demais visuais estão no dashboard (`app/dashboard.py`).

4. Visualização dos resultados (5 figuras)

Figura 1 - Valor líquido total por ano (caracterização)



Valor líquido total por ano

O gráfico de barras apresenta a soma anual do valor líquido ressarcido pela CEAP, considerando a competência de cada despesa, isto é, o ano e o mês da cota, e não apenas a data de emissão do documento. No eixo horizontal, são apresentados os anos analisados; no eixo vertical, o montante total ressarcido em reais.

O gráfico contribui para a caracterização do dataset, evidenciando o crescimento do volume agregado ao longo do período. Observa-se um aumento de aproximadamente R\$ 176 milhões em 2020 para cerca de R\$ 264 milhões em 2024, além da manutenção de um patamar elevado em 2025, com aproximadamente R\$ 250 milhões. Esses resultados indicam que a base analisada cobre um intervalo de forte movimentação financeira, contexto importante para a interpretação das questões de pesquisa seguintes.


4.1 RQ1 - Tipos de despesa (Figura 2)

Top 3 categorias	% do total
Divulgação da atividade parlamentar	33,6%
Passagem aérea (SIGEPA)	17,7%

Top 3 categorias	% do total
Locação/fretamento de veículos	14,8%

As **cinco primeiras** categorias aprox. **86%** do total (**H1** corroborada).

Figura 2 - Pareto dos tipos de despesa



Pareto tipos de despesa

Visualização que responde à RQ1 (“quais tipos de despesa concentram mais gastos”). As barras representam o valor líquido total por categoria de despesa (eixo esquerdo, em reais); a linha indica o percentual acumulado sobre o total geral (eixo direito). A leitura conjunta demonstra concentração típica de Pareto: poucas rubricas — em especial divulgação da atividade parlamentar (~33,6%), passagem aérea via SIGEPA (~17,7%) e locação/fretamento de veículos (~14,8%) — explicam a maior parte dos cerca de R\$ 1,39 bilhão do período; as cinco principais categorias somam aproximadamente 86% do total.

4.2 RQ2 - Partido e UF (Figura 3 + tabelas)


Por soma total (tamanho da bancada): PL, PT, União, PP, PSD lideram

Por mediana por deputado (top 3): PRD (R\$ 2,51 mi), PCdoB (R\$ 2,34 mi), S.PART. (R\$ 1,72 mi) - **PL não lidera (H2).**

Por UF (texto): SP lidera em soma; BA lidera em mediana por deputado

Figura 3 - Mediana do gasto por deputado, por partido

Mediana do gasto por deputado — partido (top 20)



Mediana por partido

Gráfico de barras horizontais que responde à RQ2 (“como os gastos variam por partido”), usando métrica mais adequada que a soma bruta (que favorece partidos com bancadas maiores). Para cada partido, calculou-se primeiro a soma do valor líquido de cada deputado no período 2020–2025; em seguida, a mediana desses valores — ou seja, o gasto do parlamentar “central” de cada legenda. O eixo vertical lista os partidos; o horizontal, a mediana em reais. O resultado mostra que PL e PT lideram em volume absoluto, mas não necessariamente em mediana por deputado (destaque para PRD e PCdoB), reforçando que a métrica escolhida altera a interpretação comparativa entre grupos políticos.


4.3 RQ3 - Deputados e fornecedores (Figuras 4 e 5)

Top 3 deputados (sem lideranças): Sidney Leite, General Girão, Pompeo de Mattos (~R\$ 3,3-3,5 mi no período).

Top 3 fornecedores: TAM, GOL, AZUL - alinhado a passagens aéreas (H4).


Figura 4 - Top deputados por valor liquidado

Top deputados por valor liquidado (top 15)



Top deputados

Barras horizontais com os 15 parlamentares de maior soma de valor líquido no período analisado (estruturas de liderança partidária, como registros LID/LIDER, foram excluídas). O eixo vertical traz o nome do deputado; o horizontal, o total acumulado em reais entre 2020 e 2025. Responde à RQ3 no eixo “quais deputados concentram os maiores valores”, com fins de transparência e auditoria exploratória. Os valores observados (~R\$ 3,3 a 3,5 milhões no recorte) refletem o acúmulo de seis anos de cota e não devem ser interpretados, isoladamente, como indício de irregularidade.

Figura 5 - Top fornecedores por valor liquidado

Top fornecedores

Barras horizontais com os 15 fornecedores que mais receberam recursos ressarcidos via CEAP, somando lançamentos de todos os deputados no período. O eixo horizontal indica o valor total em reais. Complementa a RQ3 (“quais fornecedores concentram os maiores valores”) e articula-se com a Figura 2: predominam companhias aéreas (TAM, GOL, AZUL), coerente com a forte participação da rubrica de passagens aéreas no total. O gráfico evidencia concentração do fluxo financeiro em poucos prestadores do setor de transporte, padrão esperado dada a natureza das despesas cobertas pela cota parlamentar.

5. Discussão dos resultados

5.1 Confronto com as questões de pesquisa

RQ	Resposta sintética	Evidência principal
RQ1	Poucos tipos concentram a maior parte dos recursos	Pareto: top 5 aprox. 86%; divulgação (33,6%) + passagens SIGEPA (17,7%)

RQ	Resposta sintética	Evidência principal
RQ2	Há variação relevante por partido e UF; métrica importa	PL/SP lideram em soma; PRD/PCdoB e BA lideram em mediana
RQ3	Gastos concentrados em fornecedores aéreos e em deputados com alto volume acumulado no período	TAM + GOL + AZUL; top deputados ~R\$ 3,3-3,5 mi em 6 anos

5.2 Insights

1. **Concentração estrutural:** a CEAP no recorte analisado é dominada por divulgação, transporte e apoio de escritório - categorias compatíveis com a finalidade da cota, mas que exigem leitura qualitativa para auditoria.
2. **Comparações entre grupos:** usar apenas soma total confunde **tamanho do grupo** com **padrão de gasto por parlamentar**; a mediana por deputado é essencial em RQ2.
3. **Assimetria dos lançamentos:** mediana (R\$ 259) muito inferior à média (R\$ 1.131) confirma distribuição assimétrica (H5).
4. **Sazonalidade:** a evolução mensal (dashboard) permite investigar picos em trabalhos futuros; a Figura 1 resume o crescimento anual.
5. **Qualidade do dado:** 42,9 mil lançamentos com valor zero e registros de liderança sem partido padronizado exigem filtros explícitos no dashboard.

5.3 Comparações e estatísticas

- **Entre anos:** valor total cresce de ~R\$ 176 mi (2020) para ~R\$ 264 mi (2024), com volume de lançamentos estável entre 208 mil e 237 mil/ano.
- **Entre métricas (RQ2):** correlação visual entre ranking por soma e por mediana é **baixa** (ex.: PL 1º em soma, 5º em mediana; PRD não aparece no top 5 de soma, mas lidera mediana).
- **Dispersão intra-partido:** o boxplot no dashboard mostra variação entre deputados do mesmo partido.

5.4 Confronto com trabalhos e literatura (Plus)

Referência / linha de trabalho	Relação com este experimento
Transparência ativa e LAI - estudos sobre abertura de dados no Legislativo brasileiro enfatizam que publicar CSV não garante compreensão;	Corroborar a escolha de um dashboard narrativo em vez de apenas disponibilizar CSV.

Referência / linha de trabalho	Relação com este experimento
visualização e agregação são necessárias (ex.: debates sobre impacto da Transparência Brasil e do Portal da Transparência).	
Projetos de jornalismo de dados (Aos Fatos, Operação Serenata de Amor / Rosie etc.)	Utilizaram CEAP para apontar concentrações e fornecedores recorrentes - alinhado às nossas RQ1 e RQ3 (corroborar padrões de concentração em poucas categorias e em fornecedores de transporte).
Críticas metodológicas em rankings de parlamentares	Rankings por soma bruta sem normalizar mandato, UF ou tempo de casa podem estigmatizar sem contexto - contesta interpretação simplista do nosso ranking RQ3; reforça necessidade de mediana, filtros e notas de rodapé (incluídas neste relatório).
GQM em experimentação de software (Basili et al.)	Objetivo de “explorar dados para decisão” mapeado em questões (RQ) e métricas (soma, mediana, %) - corroborar estrutura do laboratório.

Síntese: os achados quantitativos são **consistentes** com a literatura prática sobre CEAP (concentração e fornecedores aéreos), mas este trabalho **refina** a comparação partido/UF com mediana por deputado, reduzindo um viés comum em análises públicas superficiais.

6. Conclusão

6.1 Tomada de decisão

Com base no experimento, um gestor público, pesquisador ou cidadão pode:

- **Priorizar auditoria** nas categorias de divulgação e passagens aéreas (maior impacto financeiro).
- **Comparar partidos e UFs** usando **mediana por deputado**, não apenas volume total.
- **Monitorar fornecedores** com maior volume agregado (setor aéreo) como ponto de partida para análise de contratos e notas fiscais.
- **Reproduzir** a análise atualizando os scripts quando novos anos forem publicados.

6.2 Sugestões futuras

1. Normalizar gastos por **tempo de mandato** e **distância da capital**.
2. Cruzar CEAP com API de deputados (<https://dadosabertos.camara.leg.br/>) (dados biográficos, comissões).

3. Detectar **fornecedores compartilhados** entre deputados (grafos).
4. Incluir testes estatísticos (Kruskal-Wallis entre UFs, por exemplo).
5. Exportar o dashboard inteiro em PDF automatizado (Streamlit -> print ou pdfkit).

6.3 Resultado conclusivo

O Laboratório 04 foi concluído com **pipeline reprodutível, dashboard interativo completo e 5 figuras** neste relatório para apresentação rápida em sala. A CEAP entre 2020 e 2025 apresenta **alta concentração em poucas rubricas, diferenças metodológicas entre soma e mediana** nos recortes partidário e geográfico, e **dominância de fornecedores aéreos** nos maiores valores. A entrega atende ao trabalho alternativo (base pública + relatório com introdução, metodologia, resultados e discussão) e está pronta para conversão em PDF e apresentação em sala.

Apêndice A - Como reproduzir figuras e dashboard

```
cd C:\workspace\lab-medicao
python -m venv .venv
.\venv\Scripts\Activate.ps1
pip install -r laboratorio4/requirements.txt
.\venv\Scripts\python.exe laboratorio4/run_lab04.py
```

Apêndice B - Entregáveis do Lab04 (checklist)

Item do enunciado	Arquivo / artefato
Caracterização do dataset	Seção 3 (tabelas) + Figura 1
Visualizações RQ1	Seção 4.1 + Figura 2
Visualizações RQ2	Seção 4.2 + Figura 3 (+ tabelas UF/partido)
Visualizações RQ3	Seção 4.3 + Figuras 4-5
Dashboard interativo (todos os gráficos)	app/dashboard.py
Relatório (apresentação rápida)	Este documento - 5 figuras
Figuras exportadas	relatorios/figuras/*.png

Referências

- CÂMARA DOS DEPUTADOS. **Dados Abertos - CEAP**. Disponível em: <https://dadosabertos.camara.leg.br/>. Acesso em: 28 maio 2026.
- CÂMARA DOS DEPUTADOS. **Dados Abertos - Legislativo** (webservices). Disponível em: <https://www2.camara.leg.br/transparencia/dados-abertos/dados-abertos-legislativo>. Acesso em: 28 maio 2026.
- BASILI, V. R.; ROMBACH, H. D.; CALDIERA, G. **Goal Question Metric Paradigm**. Encyclopedia of Software Engineering, 1994.
- MICHELIN, L. et al. **Serenata de Amor**: experiência de ciência de dados cívica sobre gastos públicos. *Coding Rights* / projeto Rosie, 2016-2019.
- TRANSPARÊNCIA BRASIL. Publicação e uso de dados abertos no poder público. Materiais institucionais, 2020-2024.